

# Relatório de uma Classificação de Imagens

1<sup>st</sup> Luiz Benedito Alves Neto - 7557

*Visão Computacional*  
*Universidade Federal de Viçosa*  
Rio Paranaíba, Brasil  
luiz.b.neto@ufv.br

2<sup>nd</sup> Mariana de Deus Castro - 7583

*Visão Computacional*  
*Universidade Federal de Viçosa*  
Rio Paranaíba, Brasil  
mariana.d.castro@ufv.br

## I. INTRODUÇÃO

O objetivo deste trabalho foi desenvolver e avaliar modelos de classificação para um conjunto de imagens, utilizando os classificadores K-NN (K-Nearest Neighbors) e SVM (Support Vector Machine), com a extração de características HOG (Histogram of Oriented Gradients). Para isso, o processo foi dividido em várias etapas.

## II. ETAPAS DO PROCESSO

### A. Pré-processamento das Imagens

Primeiramente, as imagens foram carregadas e redimensionadas para um formato fixo de 128x128 pixels, garantindo uniformidade. Caso as imagens fossem coloridas, elas foram convertidas para escala de cinza, simplificando a análise sem comprometer informações relevantes.

### B. Extração de Características(HOG)

A extração das características foi realizada utilizando o método HOG, configurado com:

- Número de orientações: 9
- Tamanho das células: 8x8 pixels
- Blocos: 2x2 células

## III. DIVISÃO DO CONJUNTO DE DADOS

### A. Separação Inicial

O conjunto de dados foi dividido em:

- 70% para treinamento
- 30% para teste

Essa divisão garantiu que os modelos fossem treinados e avaliados de maneira consistente.

### B. Separação Adicional

Do conjunto de treinamento (70% do total), 25% foram separados para validação, equivalente a 20% do conjunto completo.

### C. Tamanho dos Conjuntos de Dados

- Treinamento: 315 amostras
- Validação: 105 amostras
- Teste: 180 amostras

## IV. NORMALIZAÇÃO DAS CARACTERÍSTICAS

### A. Cálculo Manual

As características foram normalizadas utilizando as médias e desvios padrões do conjunto de treinamento.

### B. Normalização com StandardScaler

A biblioteca sklearn foi utilizada para padronizar as características de forma eficiente.

### C. Resultados da Normalização

- Treinamento: Média = 0.0000, Desvio padrão = 1.0000
- Validação: Média = -0.0006, Desvio padrão = 0.9997
- Teste: Média = 0.0018, Desvio padrão = 0.9925

## V. VALIDAÇÃO CRUZADA

A divisão dos dados seguiu um esquema estruturado para garantir a validação adequada.

- Treinamento principal (70%) foi dividido em:
- Treinamento secundário (Conjunto 2): 75% do treinamento principal
- Validação: 25% do treinamento principal
- Teste: Conjunto separado (30% do total).

Essa abordagem assegura uma avaliação robusta e evita o uso de conjunto de teste durante o ajuste dos modelos.

## VI. DESENVOLVIMENTO DOS MODELOS

### A. Classificador K-NN

O primeiro modelo testado foi o K-NN, um classificador baseado em distância. Para este modelo:

- O valor de k foi variado entre 1 e 9.
- A acurácia foi calculada no conjunto de treinamento e validação para cada valor de k.
- O k ótimo foi escolhido com base na maior acurácia obtida no conjunto de validação.

### B. Classificador SVM

O modelo SVM foi configurado com:

- Kernel linear, adequado para problemas lineares separáveis.

O desempenho do SVM foi avaliado no conjunto de teste utilizando métricas como:

- Precisão
- Recall
- F1-Score

## VII. AVALIAÇÃO DOS MODELOS

### A. K-NN

Com o melhor valor de k(7), o modelo foi treinado novamente no conjunto de treinamento e avaliado no conjunto de testes.

- Acurácia obtida no conjunto de teste foi de 63%.

### B. SVM com HOG

- Acurácia do modelo no conjunto de teste foi de 88.33%.

## VIII. ANÁLISE DOS DESEMPENHOS

Ambos os modelos foram avaliados utilizando:

- Matrizes de confusão
  - Relatórios de classificação
- Essas ferramentas permitiram identificar dificuldades específicas, como a classificação incorreta de algumas classes com poucos exemplos no treinamento.

## IX. COMPARAÇÃO ENTRE OS MODELOS

Embora o K-NN tenha apresentado um bom desempenho, o SVM destacou-se pela sua capacidade de generalização, com resultados consistentes nos diferentes conjuntos de dados.

## A. K-NN

- O modelo K-NN apresentou acurácia de 63% no conjunto de testes, com um desempenho consistente entre as classes.
- Classes como beetle e apple tiveram alta precisão e recall, indicando que o modelo conseguiu identificar essas classes com confiança.
- Outras classes, como bat e bird, apresentaram baixo desempenho, possivelmente devido à confusão com outras classes visualmente semelhantes ou desequilíbrio nos dados de treinamento.
- A matriz de confusão e o relatório de classificação evidenciam as áreas de maior dificuldade para o modelo, especialmente na diferenciação entre as classes bat e bone.

## B. SVM

- O classificador SVM com HOG teve um desempenho consistente, com uma alta acurácia geral e boas métricas de F1-Score para a maioria das classes.
- A classe Apple apresentou os melhores resultados, enquanto Bat teve uma performance inferior, sugerindo que esta categoria poderia se beneficiar de ajustes nos dados ou no modelo.
- Os erros estão concentrados em previsões equivocadas entre classes visualmente similares, como Bone, Bat, e Bird.

## X. CONCLUSÃO

Este trabalho apresentou uma análise detalhada de dois modelos de classificação de imagens. A abordagem seguiu etapas de pré-processamento, extração de características, treinamento, avaliação e análise de resultados, evidenciando tanto os pontos fortes quanto as áreas para melhorias dos modelos utilizados.

O modelo SVM com HOG apresentou desempenho consistentemente superior ao KNN, tanto em termos de acurácia quanto de robustez. Sua maior eficácia justifica o maior esforço computacional e a complexidade do pré-processamento. Para a tarefa de classificação de imagens abordada, SVM com HOG é claramente a melhor abordagem.